과제 #3 결과 보고서
Marabou 를 활용한 신경망 강건성 검증

과목명: 신뢰 가능한 인공지능 (Reliable and Trustworthy AI)

제출일: 2026 년 5 월 5 일

작성자: [윤성준]

1. 대상 모델, 데이터셋 및 검증 설계

1.1 모델 및 데이터셋 선택

본 과제에서는 외부 모델인 "tiny_mnist.onnx"를 선정하였습니다. 이 모델은 MNIST 숫자 데이터셋으로 학습된 경량화된 CNN 구조입니다. Marabou 는 모델의 크기에 매우 민감하여 연산 복잡도가 높기 때문에, 과제 지침에 따라 타임아웃(Timeout)을 방지하고 합리적인 시간 내에 검증을 완료할 수 있도록 작은 크기의 아키텍처를 선택하였습니다.

1.2 검증 쿼리(Property Specification) 설계

모델의 L-infinity 강건성을 수학적으로 증명하기 위해 다음과 같은 검증 쿼리를 설계하였습니다.

- • 입력 제약 조건: 특정 입력 이미지 주변으로 $\varepsilon = 0.02$ 반경의 L-infinity ball 을 정의하였습니다 ($x_i \in [-0.02, 0.02]$).
- • 출력 제약 조건 (안전 속성): 원래 Class 0 으로 분류되어야 하는 샘플에 대해, 정의된 섭동 범위 내의 모든 입력에서 네트워크 출력 y_0 가 0.5 이상($y_0 \geq 0.5$)을 유지하는지 확인하였습니다.

2. 검증 결과 및 분석

평가 항목	결과값
검증 상태 (Status)	SAT (Satisfiable)
검증 소요 시간	157.93 ms
반례(Counter-example) 발견 여부	발견됨 (Yes)

결과 해석 (SAT 결과의 의미):

검증 결과 "SAT"이 도출되었습니다. 이는 설정된 노이즈 범위 내에서 안전 속성을 위반하는 구체적인 입력값이 존재함을 의미합니다. ε=0.02 라는 매우 미세한 노이즈에도 불구하고, 모델의 Class 0 에 대한 확신도는 -0.2351 로 급감하였으며, 최종적으로 Class 3(출력: 0.2386)으로 오분류하는 지점이 발견되었습니다. 이는 tiny_mnist 모델이 해당 적대적 공격에 취약함을 수학적으로 증명합니다.

3. Marabou 도구의 장단점 분석

3.1 장점 (Strengths)

• 수학적 엄밀함: FGSM 과 같은 경험적 공격 테스트와 달리, Marabou 는 ε-ball 내의 무한한 입력 집합 전체에 대해 속성 성립 여부를 수학적으로 증명합니다.
• API 유연성: maraboupy 파이썬 인터페이스를 통해 ONNX 모델 및 표준 데이터 구조를 손쉽게 통합하고 제어할 수 있었습니다.

3.2 한계점 및 문제 해결 (Limitations & Troubleshooting)

• 확장성 문제: 경량 모델임에도 SMT 기반 접근법은 연산 부하가 큽니다. ε 값이 커지거나 모델 깊이가 깊어질수록 검증 시간이 기하급수적으로 증가함을 확인하였습니다.
• 기술적 이슈: 구현 과정에서 최신 API 메서드 명칭 변경(getTotalTimeInMicroseconds → getTotalTimeInMicro)에 따른 호환성 문제가 있었으나 코드를 수정하여 해결했습니다. 또한 NumPy 의 float32 타입을 표준 Python float 으로 캐스팅해야 하는 제약이 있었습니다.

4. 결론

본 실험을 통해 겉보기에 안전해 보이는 소형 모델도 특정 입력 조건에서 취약점이 존재함을 확인하였습니다. Marabou 를 활용해 식별한 구체적인 오분류 사례(Class 0 → Class 3)는 향후 강건성 학습(Robust Training)이나 공식적인 방어 전략 수립의 중요한 기초 자료가 될 것입니다.